

GenBI Upload Workspace 系統擴充規格書

v0.2 draft - MVP 資料理解確認與分析資產化

GenBI Product / Architecture Draft

2026-05-22

目录

版本更新摘要	3
1. 背景與目標	3
1.1 產品定位	3
1.2 MVP 核心句子	4
2. 問題定義	4
3. 核心設計原則	4
3.1 不讓 LLM 直接猜資料	4
3.2 Dynamic metadata first	4
3.3 Human-in-the-loop confirmation	4
3.4 沿用 GenBI 既有防禦架構	5
3.5 分析結果必須可沉澱	5
4. 功能範圍	5
4.1 MVP 範圍	5
4.2 Phase 2 範圍	5
4.3 Phase 3 範圍	5
5. 使用者流程	6
5.1 主流程	6
5.2 使用者互動範例	6
6. 系統架構	6
6.1 高階架構	6
6.2 與既有 GenBI 的整合方式	7
6.3 Phase A 差異	8
7. 模組設計	8
8. 資料模型	8
8.1 uploaded_datasets	8
8.2 upload_tables	9
8.3 upload_profiles	9
8.4 upload_metadata_versions	9
8.5 upload_user_corrections	11
8.6 analysis_sessions	11
8.7 analysis_assets	11
9. Dynamic Data Understanding Layer 規格	12
9.1 Physical Schema Profiler	12
9.2 Semantic Profiler	12

9.3 Data Quality Profiler	13
9.4 Relationship Profiler (Phase 2)	13
10. Metadata Review UI 規格	13
10.1 頁面：Upload Workspace	13
10.2 Field Review Table	13
10.3 Status Code Editor	13
10.4 Grain Confirmation	13
10.5 Data Limitation Confirmation	14
10.6 Metadata Confirmation Status	14
10.7 Metadata Review MVP Acceptance Criteria	14
11. Agent Workflow 規格	14
11.1 Upload-driven Workflow	14
11.2 Phase A Prompt 差異	15
11.3 Phase B Prompt 加強規則	15
11.4 Phase C Prompt 加強規則	15
12. API / Service 介面規格	15
12.1 UploadService	15
12.2 DataProfiler	16
12.3 SemanticProfiler	16
12.4 UploadMetadataGenerator	16
12.5 UploadRepository	16
12.6 UploadAnalysisService	16
12.7 AnalysisAssetService	16
12A. Analysis Asset 規格	17
12A.1 Asset Types	17
12A.2 Save Chart	17
12A.3 Save Metric	17
12A.4 Analysis Template	17
12A.5 Saved Assets Panel	17
12A.6 Asset Lineage	17
12A.7 Analysis Asset MVP Acceptance Criteria	18
13. Execution Engine 規格	18
13.1 MVP：Pandas Engine	18
13.2 Phase 2：DuckDB Engine	18
14. 安全與治理規格	18
14.1 檔案安全	18
14.2 Code Execution Safety	18
14.3 PII / Sensitive Data	18
14.4 Retention	18
15. Observability / Debug 規格	19
16. 測試規格	19
16.1 Unit Tests	19
16.2 Integration Tests	19
16.3 Golden Test Datasets	19
16.4 Acceptance Criteria	20
16.5 MVP 新增驗收標準：Metadata Review + Analysis Assets	20
17. 開發里程碑	20
Milestone 1：Upload + Parse + Profile	20
Milestone 2：Semantic Metadata + Review UI	20
Milestone 3：Analysis Workflow Integration	20

Milestone 3A : Analysis Assets	20
Milestone 4 : Testing + Guardrails	21
Milestone 5 : DuckDB / Multi-sheet (Phase 2)	21
18. 開發拆票建議	21
Epic A : Upload Workspace 基礎設施	21
Epic B : File Parser	21
Epic C : Profiling	21
Epic D : Semantic Metadata	21
Epic E : Review UI	21
Epic F : Analysis Integration	22
Epic G : Safety / Observability / Tests	22
Epic H : Analysis Assets	22
19. 風險與對策	22
20. Definition of Done	23
21. 建議優先開發順序	23
22. 附錄：Dynamic Metadata 最小欄位規格	23
23. 附錄：MVP Prompt Context 組裝格式	24
24. 結論	24

版本更新摘要

本版在原 v0.1 draft 的 Upload Workspace 規格上，新增兩個 MVP 優先閉環：

1. **Metadata Review UI / 資料理解確認閉環**：讓 AI 對上傳資料的理解可被使用者確認與修正，包括欄位角色、單位、預設聚合、狀態碼、grain 與資料限制。
2. **Analysis Asset / 分析資產化閉環**：讓一次成功的互動式分析可以保存成 Saved Chart、Saved Metric 或簡化版 Analysis Template，避免分析結果只停留在一次性聊天輸出。

MVP 階段不追求完整 Looker Studio 式 Dashboard Builder，而是優先完成「AI 懂資料」與「分析可沉澱」兩個最小可行能力。完整 dashboard canvas、分享、排程寄送、多表自動 join 與企業治理，保留到 Phase 2/3。

1. 背景與目標

現有 GenBI 採用 schema-driven 架構：系統透過預先定義的 domain metadata 理解資料結構、KPI、限制與圖表建議，並透過多階段 agentic workflow 完成自然語言分析、資料處理、視覺化與洞察產生。

本次擴充目標是新增一條 **upload-driven / ad-hoc analysis** 路線，讓使用者可自行上傳 CSV、Excel、Parquet 等資料檔案，不必先由開發團隊撰寫固定 metadata，即可進入高互動式資料探索與圖表分析流程。

本功能不取代現有 schema-driven GenBI，而是補足臨時性、探索性、自助式分析場景。

1.1 產品定位

項目	現有 schema-driven GenBI	新增 Upload Workspace
資料來源	已建模 domain / MongoDB collection	使用者上傳 CSV / Excel / Parquet
Metadata 來源 使用情境	人工維護、版本化 metadata 正式企業資料分析、穩定 KPI、可治理 domain	系統動態產生 + 使用者確認 臨時資料、Excel 報表、專案表、一次性探索
準確性	高，可測試、可治理	中高，需 human-in-the-loop 確認

項目	現有 schema-driven GenBI	新增 Upload Workspace
主要風險 核心能力	metadata 維護成本 Schema-driven BI Agent	AI 誤解欄位語意、資料品質不穩 Dynamic Data Understanding Layer

1.2 MVP 核心句子

MVP 階段的 Upload Workspace 不追求完整 Dashboard Builder，而是優先完成兩個核心閉環：

- 第一，讓 AI 對資料的理解可被使用者確認與修正。
- 第二，讓一次成功的分析可以沉澱為可重用的 **chart**、**metric** 或 **analysis template**。

透過這兩個閉環，系統才能從一次性的 ad-hoc chat analysis，逐步演進為可治理、可重用、可產品化的 GenBI 分析資產平台。

2. 問題定義

使用者上傳的資料檔通常缺乏正式 metadata。AI 若只根據欄位名稱與少量 sample rows 直接產生分析，很容易發生以下問題：

1. 將 ID 欄位誤認為可加總數值。
2. 將數字型狀態碼誤認為 measure。
3. 不知道每列資料的 grain，例如一列代表一個專案、一張申請單、每日 snapshot，或一筆明細。
4. 不知道欄位單位，例如天、元、%、小時、人次。
5. 不知道狀態碼含義，例如 R 是 Rejected、Returned、Resolved 或 Retired。
6. 不知道 KPI 分母定義，例如完成率是否排除取消件。
7. 不知道資料限制，例如沒有日期欄卻要求趨勢分析。
8. 不知道跨 sheet 或跨表關係。
9. 不知道資料內是否含總計列、重複列、空白列或異常格式。

因此本功能的核心不是「LLM 直接讀上傳檔案」，而是：

上傳資料 -> 動態資料剖析 -> 產生暫時 metadata -> 使用者確認 -> 進入互動式分析 -> 持續修正 metadata

3. 核心設計原則

3.1 不讓 LLM 直接猜資料

LLM 不應直接面對 raw file 產生最終分析。系統必須先建立一份 machine-readable metadata profile，再由 LLM 基於該 profile 進行 planning、transformation、charting 與 insight。

3.2 Dynamic metadata first

每份上傳資料都必須產生一份 dynamic metadata，至少包含：dataset id、file metadata、table / sheet list、row count、column count、欄位型別、缺失值比例、distinct count、sample values、semantic role 推論、possible primary key、data limitations、recommended analysis、recommended charts、user corrections。

3.3 Human-in-the-loop confirmation

系統必須提供「AI 對資料的理解」確認畫面，讓使用者快速修正欄位語意、單位、狀態碼、資料粒度與限制。未經確認的 metadata 可以進行探索，但應顯示 confidence 與風險提示。

3.4 沿用 GenBI 既有防禦架構

Upload Workspace 必須延續既有 GenBI 的設計精神：phase-based workflow、metadata-driven prompt context、q_columns lock、retry / fallback、table fallback、execution log、call telemetry、test case repository、prompt repository、domain isolation。

3.5 分析結果必須可沉澱

MVP 新增 Analysis Asset 概念。每次成功分析不應只停留在聊天訊息，而應能保存為 chart、metric 或 template，並與 dataset_id、metadata_version、source_query、lineage 綁定。

4. 功能範圍

4.1 MVP 範圍

MVP 聚焦於單一上傳檔案、單一主要表格的互動式分析。

支援：

1. CSV 上傳。
2. Excel 單 sheet 上傳。
3. 自動欄位剖析。
4. 自動 semantic role 推論。
5. 使用者確認與修正欄位語意。
6. 自動產生 dynamic metadata。
7. 自然語言資料分析。
8. ECharts / Plotly 圖表生成。
9. KPI cards / table fallback。
10. 分析歷程保存。
11. 使用者修正 metadata 後重跑分析。
12. Saved Chart。
13. Saved Metric。
14. 簡化版 Analysis Template。
15. Saved Assets Panel。

MVP 暫緩：完整 dashboard canvas、拖拉式排版、scheduled delivery、多人協作、embed report、多表自動 join、複雜 Excel 清理。

4.2 Phase 2 範圍

1. Excel 多 sheet。
2. 自動偵測 sheet relationship。
3. 多表 join key 推論。
4. 使用者確認 table relationship。
5. Profile versioning。
6. Dataset reuse。
7. 匯出成正式 GenBI metadata。
8. 支援 Parquet。
9. 支援 DuckDB SQL execution path。
10. Analysis Template 跨相似 schema 檔案套用。

4.3 Phase 3 範圍

1. 企業 data catalog 整合。
2. PII / sensitive data detection 強化。
3. 權限與資料保留策略。
4. Profile approval workflow。

5. Dataset sharing ◦
6. Scheduled refresh ◦
7. Report template generation ◦
8. 正式 dashboard publish ◦
9. Team Workspace ◦
10. Scheduled PDF / CSV delivery ◦

5. 使用者流程

5.1 主流程

User enters Upload Workspace

- > Upload CSV / Excel / Parquet
- > System parses file and creates staging table
- > System profiles physical schema and data quality
- > System infers semantic metadata
- > User reviews AI understanding
- > User confirms / edits metadata
- > System creates active dynamic metadata version
- > User asks natural language question
- > Agent plans analysis using dynamic metadata
- > System executes transform and visualization
- > User reviews chart / table / insight
- > User saves useful result as chart / metric / template
- > User gives follow-up or corrects metadata
- > Metadata updated and analysis reruns if needed

5.2 使用者互動範例

1. 使用者上傳 project_leadtime.xlsx ◦
2. 系統顯示：偵測到 1 個 sheet、120 rows、8 columns；project_id 推論為 identifier；leadtime 推論為 duration measure；status 推論為 categorical status；未偵測到可靠日期欄位，因此趨勢分析暫不支援。
3. 使用者修正：leadtime 單位為 calendar days；status = C 表示 Completed；status = D 表示 Delayed。
4. 使用者詢問：「幫我畫專案 leadtime 的分佈，並標示平均、中位數、P95。」
5. 系統產生 histogram / smoothed line chart，並顯示統計值。
6. 使用者按下「保存這張圖」。系統建立 Saved Chart。
7. 使用者按下「保存 P95 為 KPI」。系統建立 Saved Metric 並更新 dynamic metadata。
8. 使用者追問：「改成依照專案類型分組比較。」
9. 系統沿用前次分析上下文與 dynamic metadata，重跑 groupby chart。

6. 系統架構

6.1 高階架構

Streamlit / Web UI

- Upload page
- Data understanding review page
- Chat analysis workspace
- Saved assets panel
- Debug / execution log

|

Upload Workspace Orchestrator

- file validation
- parse orchestration
- profiling orchestration

- metadata confirmation flow
- analysis session binding
- |
- Dynamic Data Understanding Layer
 - physical schema profiler
 - semantic profiler
 - data quality profiler
 - relationship profiler
 - metadata generator
 - user correction manager
- |
- Dynamic Metadata Repository
 - uploaded_datasets
 - upload_tables
 - upload_profiles
 - upload_metadata_versions
 - upload_user_corrections
 - analysis_assets
 - analysis_sessions
- |
- GenBI Agent Workflow
 - intent router
 - plan
 - data extraction
 - preprocess
 - visualization
 - insight
- |
- Execution Engine
 - Pandas / DuckDB
 - ECharts / Plotly
 - sandboxed code execution

6.2 與既有 GenBI 的整合方式

新增 MetadataProvider 抽象層：

```
class MetadataProvider:
    def get_metadata(self, dataset_id: str) -> dict:
        raise NotImplementedError

class StaticDomainMetadataProvider(MetadataProvider):
    """ 讀取既有 domain_metadata collection 或 embedded_metadata """

class UploadMetadataProvider(MetadataProvider):
    """ 讀取上傳資料產生的 dynamic metadata """
```

既有 LLMService 應調整為可接受任意 metadata provider 提供的 metadata：

```
metadata = metadata_provider.get_metadata(dataset_id)
llm_service = LLMService(
    api_url=LLM_API_URL,
    api_key=LLM_API_KEY,
    model_name=LLM_MODEL,
    task_metadata=metadata,
    prompt_repo=prompt_repo,
    domain=dataset_id,
)
```

6.3 Phase A 差異

既有 schema-driven GenBI 的 Phase A 產生 MongoDB aggregation pipeline。Upload Workspace 的 Phase A 不應產生 MongoDB pipeline，而應改為：

- MVP：Pandas row filtering / selection code。
- Phase 2：DuckDB SQL，再回傳 DataFrame。

7. 模組設計

模組	建議檔案	職責
Upload service	upload_service.py	檔案上傳、驗證、儲存、staging table 建立
File parser	file_parser.py	CSV / Excel / Parquet 解析
Data profiler	data_profiler.py	physical schema、missing、distinct、range、distribution
Semantic profiler	semantic_profiler.py	推論欄位語意 role、unit、measure/dimension/id/date
Metadata generator	upload_metadata_generator.py	將 profile 轉成 GenBI-compatible metadata
Correction manager	metadata_correction_service.py	使用者修正 metadata、版本化、差異紀錄
Upload repository	upload_repository.py	MongoDB CRUD：dataset、profile、metadata versions
Upload analysis service	upload_analysis_service.py	將 upload dataset 接入 GenBI workflow
Analysis asset service	analysis_asset_service.py	Save Chart / Save Metric / Template / rerun
DuckDB engine	duckdb_engine.py	Phase 2：SQL execution / cache
Upload pages	pages/05_upload_workspace.py	上傳與資料理解確認 UI
Upload admin page	pages/06_upload_datasets.py	已上傳資料集管理
Saved assets page	pages/07_saved_assets.py	已保存分析資產管理

8. 資料模型

8.1 uploaded_datasets

```
{
  "dataset_id": "upload_20260522_001",
  "dataset_name": "project_leadtime.xlsx",
  "owner": "alan",
  "source_type": "file_upload",
  "file": {
    "original_filename": "project_leadtime.xlsx",
    "stored_path": "uploads/upload_20260522_001/source.xlsx",
    "file_type": "excel",
    "file_size_bytes": 123456,
    "sha256": "..."
  },
  "status": "profiled",
  "active_metadata_version": 1,
  "created_at": "2026-05-22T00:00:00Z",
  "updated_at": "2026-05-22T00:00:00Z"
}
```


8.2 upload_tables

```
{
  "dataset_id": "upload_20260522_001",
  "table_id": "sheet1",
  "table_name": "Sheet1",
  "row_count": 120,
  "column_count": 8,
  "grain_guess": "one row per project",
  "storage": {
    "format": "parquet",
    "path": "uploads/upload_20260522_001/sheet1.parquet"
  },
  "created_at": "2026-05-22T00:00:00Z"
}
```

8.3 upload_profiles

```
{
  "dataset_id": "upload_20260522_001",
  "profile_version": 1,
  "tables": [
    {
      "table_id": "sheet1",
      "row_count": 120,
      "columns": [
        {
          "name": "project_id",
          "physical_type": "string",
          "null_pct": 0,
          "distinct_count": 120,
          "sample_values": ["PRJ-001", "PRJ-002"],
          "warnings": ["high_cardinality"]
        },
        {
          "name": "leadtime",
          "physical_type": "number",
          "null_pct": 0,
          "distinct_count": 45,
          "min": 8,
          "max": 654,
          "mean": 112.4,
          "median": 89,
          "std": 80.2,
          "p95": 300,
          "warnings": ["right_skewed"]
        }
      ]
    }
  ],
  "created_at": "2026-05-22T00:00:00Z"
}
```

8.4 upload_metadata_versions

```
{
  "dataset_id": "upload_20260522_001",
```

```

"version": 1,
"is_active": true,
"confirmation_status": "confirmed",
"confirmed_by": "alan",
"confirmed_at": "2026-05-22T00:00:00Z",
"confidence_summary": {
  "high_confidence_fields": 6,
  "medium_confidence_fields": 2,
  "low_confidence_fields": 1
},
"metadata": {
  "dataset_id": "upload_20260522_001",
  "dataset_name": "Project Leadtime Upload",
  "source_type": "upload",
  "business_context": {
    "business_description": "User uploaded project leadtime dataset for ad-hoc analysis.",
    "main_business_questions": [
      "Leadtime distribution",
      "Top delayed projects",
      "Leadtime by project type"
    ]
  }
},
"collections": {
  "sheet1": {
    "primary_key": "project_id",
    "grain": "one row per project",
    "fields": {
      "project_id": {
        "type": "string",
        "semantic_role": "identifier",
        "description": "Project identifier",
        "recommended_use": ["label", "count_distinct"],
        "not_recommended_use": ["sum", "average"],
        "confidence": 0.95,
        "user_confirmed": true
      },
      "leadtime": {
        "type": "number",
        "semantic_role": "measure_duration",
        "unit": "days",
        "description": "Project lead time in calendar days",
        "recommended_aggregations": ["avg", "median", "min", "max", "p95", "histogram"],
        "confidence": 0.86,
        "user_confirmed": true
      }
    }
  }
},
"relationships": [],
"kpi_definitions": {
  "avg_leadtime": {
    "name": "平均 Leadtime",
    "formula": "mean(leadtime)",
    "important_note": "leadtime unit is calendar days"
  },
  "p95_leadtime": {
    "name": "P95 Leadtime",

```

```

        "formula": "p95(leadtime)",
        "important_note": "Use quantile(0.95)"
    }
},
"data_limitations": {
    "missing_dimensions": ["No confirmed date column"],
    "not_supported_analysis": ["Trend analysis unless user confirms a date field"]
}
},
"created_by": "system",
"created_at": "2026-05-22T00:00:00Z"
}

```

8.5 upload_user_corrections

```

{
    "dataset_id": "upload_20260522_001",
    "metadata_version_before": 1,
    "metadata_version_after": 2,
    "corrections": [
        {
            "target": "sheet1.leadtime.unit",
            "old_value": "unknown",
            "new_value": "days",
            "reason": "User confirmed in review UI"
        }
    ],
    "created_by": "alan",
    "created_at": "2026-05-22T00:00:00Z"
}

```

8.6 analysis_sessions

```

{
    "session_id": "sess_20260522_001",
    "dataset_id": "upload_20260522_001",
    "metadata_version": 2,
    "messages": [],
    "last_analysis": {
        "query": " 畫 leadtime 分佈圖",
        "q_columns": ["bin", "project_count", "percentage"],
        "chart_type": "histogram"
    },
    "created_at": "2026-05-22T00:00:00Z",
    "updated_at": "2026-05-22T00:00:00Z"
}

```

8.7 analysis_assets

```

{
    "asset_id": "asset_20260522_001",
    "asset_type": "saved_chart | saved_metric | analysis_template",
    "dataset_id": "upload_20260522_001",
    "metadata_version": 2,
    "name": "Leadtime Distribution",
    "description": "Leadtime distribution chart with average, median and P95",
    "source_query": " 畫 leadtime 分佈圖，並標示平均、中位數、P95",
}

```

```

"asset_payload": {
  "q_columns": [],
  "chart_engine": "echarts",
  "chart_option": {},
  "metric_formula": null,
  "template_steps": null
},
"lineage": {
  "session_id": "sess_20260522_001",
  "phase_0_plan": "...",
  "phase_a_code": "...",
  "phase_b_code": "...",
  "phase_c_code": "...",
  "q_preview": []
},
"created_by": "alan",
"created_at": "2026-05-22T00:00:00Z",
"updated_at": "2026-05-22T00:00:00Z"
}

```

設計要求：asset 必須綁定 dataset_id 與 metadata_version；saved chart 必須保存 chart option 與 Q schema；saved metric 必須能回寫 dynamic metadata 的 kpi_definitions；metadata version 過期時，重新執行 asset 必須提示使用者。

9. Dynamic Data Understanding Layer 規格

9.1 Physical Schema Profiler

輸入：DataFrame 或 DuckDB relation。輸出：table profile JSON。

必須產出 row_count、column_count、column name、normalized name、physical type、null count / pct、distinct count / pct、sample values、min / max、mean / median / std、p05 / p25 / p75 / p95、top values、warnings。

9.2 Semantic Profiler

MVP semantic role 控制在下列枚舉，避免一開始過度複雜。

Semantic Role	用途
identifier	ID、編號、代碼，不可 sum / avg
dimension	可作為 group by 的分類欄位
categorical_status	狀態欄位，例如完成、退件、延遲
measure_count	可加總的數量
measure_amount	金額
measure_duration	時長，例如 leadtime、delay days
measure_percentage	百分比或比率
date_dimension	日期欄位
datetime_dimension	日期時間欄位
text_description	描述文字，不建議直接 group by
boolean_flag	是/否、True/False
unknown	系統無法判斷，需使用者確認

每個欄位都必須產生 confidence：

```

{
  "name": "leadtime",

```

```

    "semantic_role": "measure_duration",
    "confidence": 0.86,
    "reason": "Column name contains leadtime and values are numeric positive integers."
}

```

9.3 Data Quality Profiler

必須偵測：欄位缺失比例過高、欄位值全部相同、高基數類別欄位、疑似 ID 欄位、疑似總計列、重複列、數值極端值、日期解析失敗、mixed type 欄位、欄名空白、重複欄名、特殊字元欄名。

9.4 Relationship Profiler (Phase 2)

針對多 sheet / 多表資料，推論可能關聯：欄位名稱相同、一欄 unique count 接近 row count、值域重疊比例高、欄位名稱語意相似。

10. Metadata Review UI 規格

10.1 頁面：Upload Workspace

頁面路徑：pages/05_upload_workspace.py。

區塊：File upload panel、Parse preview、Data profile summary、AI understanding review、Field editor、Data limitation editor、Confirm metadata button、Start analysis button、Saved Assets entry。

10.2 Field Review Table

欄位	顯示內容	可編輯
Column	原始欄名	否
Type	physical type	可覆寫
Semantic Role	AI 推論角色	可選下拉
Description	AI 生成描述	可編輯
Unit	單位	可編輯
Aggregation	sum / avg / count / median / no_agg	可選
Is Dimension	是否可作為分組維度	可選
Is Measure	是否可作為 measure	可選
Is Identifier	是否為 ID	可選
Confidence	信心分數	否
Warnings	資料品質警示	否

10.3 Status Code Editor

當欄位被判定為 categorical_status 時，UI 應顯示 allowed values 編輯器。

Value	Count	AI Guess	User Description
C	50	Completed	可編輯
D	20	Delayed	可編輯
X	5	Unknown	可編輯

10.4 Grain Confirmation

系統必須顯示或詢問：「AI 推論：每列資料可能代表一個 project。是否正確？」

選項：正確、改成每列代表一筆申請、改成每列代表一筆明細、自訂描述。

10.5 Data Limitation Confirmation

顯示系統自動推論的限制，例如不支援趨勢分析、不支援金額分析、不支援跨表分析。使用者可以確認，也可以指定對應欄位來解除限制。

10.6 Metadata Confirmation Status

MVP 必須在 metadata version 與欄位層級記錄確認狀態。

```
{
  "confirmation_status": "draft | confirmed | needs_review",
  "confirmed_by": "alan",
  "confirmed_at": "2026-05-22T00:00:00Z",
  "confidence_summary": {
    "high_confidence_fields": 6,
    "medium_confidence_fields": 2,
    "low_confidence_fields": 1
  }
}
```

UI 行為：尚未確認 metadata 時，分析工作區必須顯示 Unconfirmed Metadata warning badge；使用者可以在未確認狀態下試跑探索分析，但 insight 中必須提示欄位語意尚未確認；使用者按下 Confirm Metadata 後，系統產生 active metadata version；若使用者後續修改欄位語意，系統必須產生新 metadata version，不可覆寫舊版。

10.7 Metadata Review MVP Acceptance Criteria

1. 使用者上傳檔案後，系統必須顯示資料集摘要、欄位列表與 sample values。
2. 每個欄位都必須有 physical type、semantic role、description、confidence。
3. 使用者可修改 semantic role、description、unit、default aggregation。
4. 使用者可確認 grain，例如「每列代表一個 project」。
5. 使用者按下 Confirm Metadata 後，系統產生 active metadata version。
6. 若 metadata 尚未確認，進入分析時必須顯示提醒。
7. semantic_role = identifier 的欄位不得被 sum / avg。
8. 若沒有日期欄，使用者問趨勢分析時，系統必須拒絕或要求指定日期欄。

11. Agent Workflow 規格

11.1 Upload-driven Workflow

[Pre-Phase U0 • Upload Intent Router]

- upload_help / data_overview / metadata_edit / analysis
- follow-up detection

[Phase U1 • Dynamic Metadata Retrieval]

- load active upload metadata
- load table profile summary
- load user corrections
- load saved metrics

[Phase 0 • Plan]

- 使用 dynamic metadata 規劃 A/B/C
- 若 data limitations 不支援 -> REFUSE

[Phase A • Data Extraction]

- MVP: Pandas row filtering / selection
- Phase 2: DuckDB SQL

[Phase B • Data Processing]

- Pandas transform
- 3 次 retry
- q_columns lock
- no hallucinated columns

[Phase C • Visualization]

- ECharts option / Plotly fig
- chart fallback
- table fallback

[Phase D • Insight]

- based on Q preview
- must mention data limitations

[Phase E • Asset Save]

- save chart / metric / template on user action

11.2 Phase A Prompt 差異

Upload Workspace 不使用 MongoDB pipeline。Phase A prompt 應新增或替換為：

你是資料篩選工程師。raw_df 已經載入，欄位由 dynamic metadata 定義。請只產生 Pandas code，從 raw_df 取得分析所需明細資料，輸出 filtered_df。禁止讀檔、禁止外部 IO、禁止新增不存在欄位。

11.3 Phase B Prompt 加強規則

1. ID 欄位不得做 sum / avg。
2. semantic_role = identifier 的欄位只能用於 count distinct、label、join、group key。
3. 只有 measure 欄位可做 sum / avg / median / p95。
4. 若欄位 confidence < 0.6，使用前必須保守處理，或在 insight 中提示不確定性。
5. 若資料含 possible_total_row，必須先排除總計列再計算。
6. 若使用者問題要求 metadata 中 data_limitations 不支援的分析，必須拒絕。

11.4 Phase C Prompt 加強規則

1. 圖表使用的欄位必須來自 Q.columns。
2. 若 Q row 數 > 1000，預設不畫完整散點，應 sampling 或 aggregation。
3. 日期欄位需排序。
4. 長尾分佈建議 log scale 或 top N。
5. histogram 必須使用已計算 bin，不要在 Phase C 重新 binning，除非 Phase B 已明確保留 raw values。

12. API / Service 介面規格

12.1 UploadService

```
class UploadService:
    def upload_file(self, file_obj, owner: str) -> dict:
        """ 儲存原始檔案，建立 uploaded_datasets document。 """

    def parse_file(self, dataset_id: str) -> dict:
        """ 解析檔案，產生 table parquet 與 upload_tables。 """

    def delete_dataset(self, dataset_id: str, owner: str) -> bool:
        """ 刪除資料集與相關暫存檔。 """
```

12.2 DataProfiler

```
class DataProfiler:
    def profile_table(self, df: pd.DataFrame, table_id: str) -> dict:
        """ 產生 physical schema profile 與 data quality profile """

    def profile_dataset(self, dataset_id: str) -> dict:
        """ 針對 dataset 所有 table 產生 profile """
```

12.3 SemanticProfiler

```
class SemanticProfiler:
    def infer_columns(self, profile: dict, sample_rows: list[dict]) -> dict:
        """ 推論欄位 semantic role、description、unit、aggregation """

    def infer_dataset_limitations(self, semantic_profile: dict) -> dict:
        """ 推論 data limitations """
```

12.4 UploadMetadataGenerator

```
class UploadMetadataGenerator:
    def generate_metadata(self, dataset_id: str, profile: dict, semantic_profile: dict) -> dict:
        """ 產生 GenBI-compatible metadata """

    def apply_user_corrections(self, metadata: dict, corrections: list[dict]) -> dict:
        """ 套用使用者修正並產生新 metadata version """
```

12.5 UploadRepository

```
class UploadRepository:
    def create_dataset(self, doc: dict) -> str: ...
    def get_dataset(self, dataset_id: str) -> dict | None: ...
    def list_datasets(self, owner: str | None = None) -> list[dict]: ...
    def save_profile(self, dataset_id: str, profile: dict) -> int: ...
    def get_latest_profile(self, dataset_id: str) -> dict | None: ...
    def save_metadata_version(self, dataset_id: str, metadata: dict, created_by: str, activate: bool = True): ...
    def get_active_metadata(self, dataset_id: str) -> dict: ...
    def save_corrections(self, dataset_id: str, corrections: list[dict], user: str) -> str: ...
```

12.6 UploadAnalysisService

```
class UploadAnalysisService:
    def start_session(self, dataset_id: str, user: str) -> str: ...
    def run_query(self, session_id: str, query: str) -> dict: ...
    def rerun_with_metadata_version(self, session_id: str, metadata_version: int) -> dict: ...
```

12.7 AnalysisAssetService

```
class AnalysisAssetService:
    def save_chart(self, session_id: str, analysis_result: dict, name: str, user: str) -> str: ...
    def save_metric(self, session_id: str, metric_spec: dict, user: str) -> str: ...
    def save_template(self, session_id: str, template_spec: dict, user: str) -> str: ...
    def list_assets(self, dataset_id: str, asset_type: str | None = None) -> list[dict]: ...
    def get_asset(self, asset_id: str) -> dict | None: ...
    def rerun_asset(self, asset_id: str, target_metadata_version: int | None = None) -> dict: ...
    def delete_asset(self, asset_id: str, user: str) -> bool: ...
```


12A. Analysis Asset 規格

MVP 不做完整 Looker Studio 式 dashboard builder，但必須支援將成功分析結果沉澱為可重用資產。

12A.1 Asset Types

Asset Type	MVP 是否做	說明
Saved Chart	要做	保存某次分析產生的圖表
Saved Metric	要做	保存某次分析中產生的 KPI / 計算邏輯
Analysis Template	建議做簡化版	保存「問題 + 分析流程」，同一 dataset 可重跑
Dashboard	暫緩	MVP 只做 saved assets list，不做完整拖拉 canvas
Scheduled Report	暫緩	Phase 2/3 再做

12A.2 Save Chart

使用者在分析結果頁可點選「保存這張圖」。系統必須保存 asset_id、asset_type、dataset_id、metadata_version、source_query、title、description、q_columns、chart_engine、chart_option、phase_b_code、phase_c_code、created_by、created_at。

MVP 不需要 dashboard canvas；Saved Chart 只需能在 Saved Assets 清單中重新打開、重新命名、刪除與重新執行。

12A.3 Save Metric

當分析產生有價值的 KPI，例如平均 leadtime、P95 leadtime、完成率、延遲率、每人平均申請數，使用者可以點選「保存為 KPI」。

MVP 要求：

1. 使用者可修改 metric name。
2. 使用者可修改 description。
3. 使用者可確認公式語意。
4. 保存後，後續分析可以引用該 KPI。
5. 保存後，metadata version 應更新，並寫入 kpi_definitions。

12A.4 Analysis Template

MVP 的 Analysis Template 採簡化版：同一 dataset 內可重新執行，不要求跨 dataset 套用。Phase 2 再支援套用到欄位相似的新檔案。

12A.5 Saved Assets Panel

新增 UI 區塊：Saved Assets。

MVP 提供三個 tab：Saved Charts、Saved Metrics、Analysis Templates。

每個 asset 至少支援查看、重新執行、重新命名、刪除。加入 Dashboard、分享與排程暫緩。

12A.6 Asset Lineage

每個 asset 必須保存 lineage，至少包含 session_id、source query、metadata_version、Phase 0 plan、Phase A code / SQL、Phase B code、Phase C code / option、Q columns、Q preview、created_by / created_at。

12A.7 Analysis Asset MVP Acceptance Criteria

1. 使用者完成一次分析後，可以保存圖表為 Saved Chart。
2. Saved Chart 必須保存 query、metadata_version、Q schema、chart option 與產生 code。
3. 使用者可以從 Saved Assets 清單重新開啟 Saved Chart。
4. 使用者可以將某個分析結果保存為 Saved Metric。
5. Saved Metric 必須寫回 dynamic metadata 的 kpi_definitions。
6. 後續使用者可用自然語言引用已保存 KPI。
7. 使用者可以刪除 Saved Asset。
8. Asset 必須綁定 dataset_id 與 metadata_version，以確保可追溯。
9. 若 metadata_version 已過期，重新執行 asset 時需提示使用者。

13. Execution Engine 規格

13.1 MVP：Pandas Engine

流程：從 `upload_tables.storage.path` 讀取 parquet；載入成 DataFrame；套用 Phase A 產生的 filtering code；交給 Phase B。

限制：預設 row limit 為 100,000 rows。若超過 row limit，UI 顯示警告，並要求使用者抽樣或使用 DuckDB path。所有 code execution 必須在受限 namespace 內執行。

13.2 Phase 2：DuckDB Engine

DuckDB Engine 提供 register parquet table、execute generated SQL、return pandas DataFrame、支援 LIMIT guard、支援 query explain / debug log。

14. 安全與治理規格

14.1 檔案安全

1. 檔案大小限制：MVP 預設 100MB。
2. 副檔名白名單：.csv, .xlsx, .xls, .parquet。
3. 檔案需計算 SHA256。
4. 上傳檔案不得直接以原始檔名作為系統路徑。
5. Excel macro 不執行。
6. 錯誤檔案需顯示可理解錯誤訊息。

14.2 Code Execution Safety

1. 禁止 LLM 產生 open, read_csv, read_excel, os, subprocess, requests, socket。
2. exec namespace 只提供 pd, np, raw_df, filtered_df, Q。
3. 禁止外部 IO。
4. 設定 execution timeout。
5. 設定 DataFrame row / column limit。

14.3 PII / Sensitive Data

MVP 至少偵測 email、phone、address-like text、national id pattern、employee id、name-like column。若偵測到 PII，metadata 標記 semantic_role = pii，預設不在 chart label 或 insight 中逐筆列出。

14.4 Retention

MVP 預設：原始上傳檔保留 30 天；Parquet staging 保留 30 天；Metadata / profile / corrections / assets 可長期保留；使用者可手動刪除 dataset。

15. Observability / Debug 規格

每次 upload / profile / analysis / asset save 應保存 dataset_id、session_id、metadata_version、query、phase outputs、generated code、execution time、row count before / after transform、chart option、errors and retry logs、LLM token usage、fallback reason、asset lineage。

UI debug panel 應顯示：Active metadata version、Field profile summary、Phase 0 plan、Phase A code / SQL、Phase B code、Phase C option、Q preview、retry log、asset payload。

16. 測試規格

16.1 Unit Tests

測試項目	檔案
CSV parser	test_file_parser.py
Excel parser	test_file_parser_excel.py
Physical profiler	test_data_profiler.py
Semantic role inference	test_semantic_profiler.py
Metadata generation	test_upload_metadata_generator.py
Correction application	test_metadata_correction_service.py
Repository CRUD	test_upload_repository.py
Pandas execution guard	test_upload_execution_engine.py
Analysis assets	test_analysis_asset_service.py

16.2 Integration Tests

1. 上傳乾淨 CSV，完成 profile，確認 metadata。
2. 上傳 Excel 單 sheet，完成 profile，確認 metadata。
3. ID 欄位不得被加總。
4. 沒有日期欄時，趨勢分析應拒絕。
5. 有日期欄時，趨勢分析應成功。
6. status code 經使用者修正後，後續分析應採用修正後語意。
7. 可能總計列應被標示並排除。
8. Phase C 失敗時 fallback table。
9. follow-up query 能沿用 last_analysis。
10. metadata version 更新後可 rerun。
11. 保存 Saved Chart 後可重新開啟。
12. 保存 Saved Metric 後可被後續分析引用。

16.3 Golden Test Datasets

檔案	用途
projects_clean.csv	基本 happy path
projects_with_total_row.csv	總計列偵測
projects_no_date.csv	data limitation refusal
projects_with_date.csv	trend analysis
sales_amount.csv	金額欄位與加總
employee_pii.csv	PII 偵測
mixed_type_column.csv	mixed type warning
multi_sheet_basic.xlsx	Phase 2 多 sheet

16.4 Acceptance Criteria

MVP 完成標準：

1. 可以上傳 CSV / Excel 單 sheet。
2. 可以產生 physical profile 與 semantic metadata。
3. 可以讓使用者確認並修正 metadata。
4. 可以儲存 metadata version。
5. 可以使用 dynamic metadata 啟動 GenBI workflow。
6. 可以完成資料概覽、欄位分佈、Top N / Bottom N、groupby bar chart、histogram、統計摘要、time trend、stacked bar、KPI cards、table fallback。
7. 可以處理錯誤與 fallback，不讓使用者看到 crash。
8. 可以在 debug panel 追蹤每個 phase。
9. 具備基本安全限制。
10. 通過 MVP integration test suite。

16.5 MVP 新增驗收標準：Metadata Review + Analysis Assets

1. 使用者上傳檔案後，可以進入 Metadata Review UI，並看見資料集摘要、欄位列表、sample values 與 confidence。
2. 使用者可以修改欄位 semantic role、description、unit、default aggregation。
3. 使用者可以確認 grain，並產生 active metadata version。
4. 尚未確認 metadata 時，分析工作區必須顯示提醒。
5. 使用者完成分析後，可以保存圖表為 Saved Chart。
6. Saved Chart 可以從 Saved Assets 清單重新開啟與重新執行。
7. 使用者可以把分析中產生的 KPI 保存為 Saved Metric。
8. Saved Metric 必須回寫 dynamic metadata 的 `kpi_definitions`。
9. 後續自然語言分析可以引用已保存 KPI。
10. 所有 asset 必須綁定 `dataset_id`、`metadata_version` 與 lineage。

17. 開發里程碑

Milestone 1：Upload + Parse + Profile

交付：Upload page、CSV parser、Excel single sheet parser、Parquet staging、physical schema profiler、upload repository、profile display UI。

驗收：上傳檔案後可看到欄位 profile 與 sample data。

Milestone 2：Semantic Metadata + Review UI

交付：semantic profiler、metadata generator、field review table、status code editor、grain confirmation、data limitation editor、metadata versioning。

驗收：使用者可確認 / 修正 metadata，並儲存 active metadata version。

Milestone 3：Analysis Workflow Integration

交付：UploadMetadataProvider、UploadAnalysisService、Pandas Phase A path、Phase B/C/D reuse、session binding、follow-up support、table fallback。

驗收：使用者可針對上傳資料聊天分析並產生圖表。

Milestone 3A：Analysis Assets

交付：analysis_assets collection、Save Chart、Save Metric、簡化版 Analysis Template、Saved Assets Panel、asset lineage、metric 回寫 dynamic metadata `kpi_definitions`。

驗收：使用者可將一次成功分析保存為 chart / metric / template，並可重新開啟或重新執行。

Milestone 4 : Testing + Guardrails

交付：golden datasets、unit tests、integration tests、execution safety guard、PII detection basic、debug panel。

驗收：通過 MVP acceptance criteria。

Milestone 5 : DuckDB / Multi-sheet (Phase 2)

交付：DuckDB engine、SQL Phase A、multi-sheet parser、relationship profiler、relationship confirmation UI。

驗收：可針對多 sheet Excel 進行基本跨表分析。

18. 開發拆票建議

Epic A : Upload Workspace 基礎設施

- A1：建立 uploaded_datasets / upload_tables / upload_profiles collections。
- A2：實作 UploadRepository。
- A3：實作 UploadService.upload_file()。
- A4：實作檔案儲存與 SHA256。
- A5：實作 Streamlit upload page。

Epic B : File Parser

- B1：CSV parser。
- B2：Excel single sheet parser。
- B3：欄名 normalize。
- B4：Parquet staging。
- B5：sample preview。

Epic C : Profiling

- C1：Physical schema profiler。
- C2：Data quality warning rules。
- C3：Possible total row detection。
- C4：Possible primary key detection。
- C5：Profile persistence。

Epic D : Semantic Metadata

- D1：Rule-based semantic profiler。
- D2：LLM-assisted semantic profiler。
- D3：Semantic confidence scoring。
- D4：Metadata generator。
- D5：GenBI-compatible metadata validation。

Epic E : Review UI

- E1：Field review table。
- E2：Semantic role dropdown。
- E3：Unit / description editor。
- E4：Status code editor。
- E5：Data limitation editor。

- E6 : Confirm metadata button ◦
- E7 : Metadata confirmation status badge ◦

Epic F : Analysis Integration

- F1 : MetadataProvider abstraction ◦
- F2 : UploadMetadataProvider ◦
- F3 : UploadAnalysisService ◦
- F4 : Pandas Phase A prompt ◦
- F5 : Workflow integration with existing Phase B/C/D ◦
- F6 : Analysis session persistence ◦

Epic G : Safety / Observability / Tests

- G1 : Execution sandbox restrictions ◦
- G2 : Timeout / row limit guard ◦
- G3 : PII detection basic ◦
- G4 : Debug panel ◦
- G5 : Unit tests ◦
- G6 : Golden dataset integration tests ◦

Epic H : Analysis Assets

- H1 : 建立 analysis_assets collection 與 indexes ◦
- H2 : 實作 Save Chart ◦
- H3 : 實作 Save Metric ◦
- H4 : 實作簡化版 Analysis Template ◦
- H5 : 實作 Saved Assets Panel ◦
- H6 : 實作 asset 重新執行 ◦
- H7 : 實作 Saved Metric 回寫 kpi_definitions ◦
- H8 : 實作 metadata version 過期提示 ◦

19. 風險與對策

風險	影響	對策
AI 誤判欄位語意	分析錯誤	Review UI + confidence + user correction
Excel 格式複雜	parser 失敗	MVP 限制乾淨表格，Phase 2 再支援複雜格式
LLM 產生錯誤 Pandas code	crash 或錯誤結果	retry + cheatsheet + q_columns lock + table fallback
上傳檔過大	效能差	row limit、DuckDB path、sampling
資料含 PII	資安風險	PII detection、masking、retention policy
使用者不確認 metadata 就分析	誤用	顯示 unconfirmed badge 與 confidence warning
metadata 版本混亂	分析不可追溯	analysis session 綁定 metadata_version
saved asset 來源不清	無法治理	asset lineage 必填
saved metric 公式錯誤	後續分析錯誤	metric review + required_fields + metadata versioning

20. Definition of Done

本功能 MVP 視為完成，需同時滿足：

1. 可以上傳 CSV / Excel 單 sheet。
2. 可以產生 physical profile 與 semantic metadata。
3. 可以讓使用者確認並修正 metadata。
4. 可以儲存 metadata version。
5. 可以使用 dynamic metadata 啟動 GenBI workflow。
6. 可以完成常見互動式分析與圖表。
7. 可以處理錯誤與 fallback，不讓使用者看到 crash。
8. 可以在 debug panel 追蹤每個 phase。
9. 可以保存 Saved Chart。
10. 可以保存 Saved Metric，並回寫 dynamic metadata。
11. 可以保存簡化版 Analysis Template。
12. 可以從 Saved Assets Panel 查看、重新執行、重新命名、刪除 asset。
13. 具備基本安全限制。
14. 通過 MVP integration test suite。

21. 建議優先開發順序

1. CSV single-table happy path。
2. Physical profile。
3. Semantic profile。
4. Metadata Review UI。
5. Confirm metadata version。
6. 接 GenBI workflow。
7. Save Chart。
8. Save Metric。
9. Saved Assets Panel。
10. Excel single sheet。
11. Data quality warnings。
12. PII 與 safety guard。
13. DuckDB 與 multi-sheet。

真正的產品風險不是 parser，而是「dynamic metadata 是否足以讓 GenBI 正確分析」。因此應盡快打通從 profile -> metadata -> chat analysis -> asset save 的 end-to-end loop。

22. 附錄：Dynamic Metadata 最小欄位規格

```
{
  "name": "leadtime",
  "type": "number",
  "semantic_role": "measure_duration",
  "description": "Project lead time in days",
  "unit": "days",
  "nullable": false,
  "sample_values": [8, 14, 30],
  "stats": {
    "min": 8,
    "max": 654,
    "mean": 112.4,
    "median": 89,
    "p95": 300
  },
  "recommended_use": ["histogram", "average", "median", "p95", "group_compare"],
}
```

```
"not_recommended_use": [],  
"confidence": 0.86,  
"user_confirmed": true  
}
```

23. 附錄：MVP Prompt Context 組裝格式

```
### Uploaded Dataset: <dataset_name>  
  
# Dataset Grain  
<user confirmed grain or AI guessed grain>  
  
# Tables and Fields  
<table_name>  
- <field_name> (<physical_type>, <semantic_role>, confidence=<score>)  
  description: <description>  
  unit: <unit>  
  allowed_values: <if categorical>  
  recommended_use: <list>  
  not_recommended_use: <list>  
  
# Data Quality Warnings  
- <warning list>  
  
# KPI Definitions  
- <generated or user-confirmed KPI definitions>  
  
# Saved Metrics  
- <metric list from analysis_assets / kpi_definitions>  
  
# Data Limitations  
- <limitations>  
  
# Charting Guidance  
- <recommended chart mapping>  
  
# User Corrections  
- <latest corrections>
```

24. 結論

Upload Workspace 的本質是為 GenBI 增加一個 dynamic metadata generation layer。開發重點不是單純上傳檔案，也不是讓 LLM 直接讀檔，而是建立一個可確認、可版本化、可回饋修正的資料理解流程。

v0.2 進一步補上 Analysis Asset 機制，讓一次成功的分析可以沉澱成 chart、metric 或 template。完成後，GenBI 將同時具備兩種能力：

1. 正式資料集：schema-driven、穩定、可治理。
2. 臨時資料集：upload-driven、快速、自助、互動式探索。

兩條路線最終都應收斂到相同的 GenBI agent workflow，以降低維護成本並提高產品一致性。